

# **Big Data**

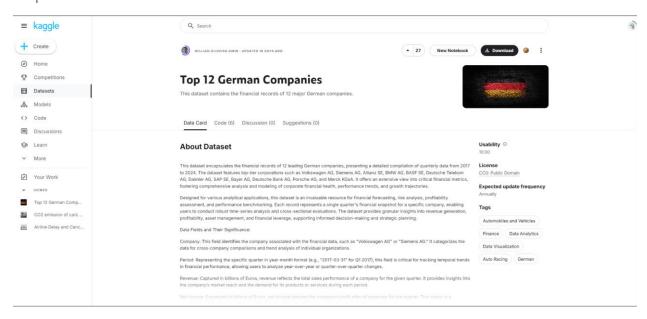
06/12/2024

Jon Fernandez de Gorostiza

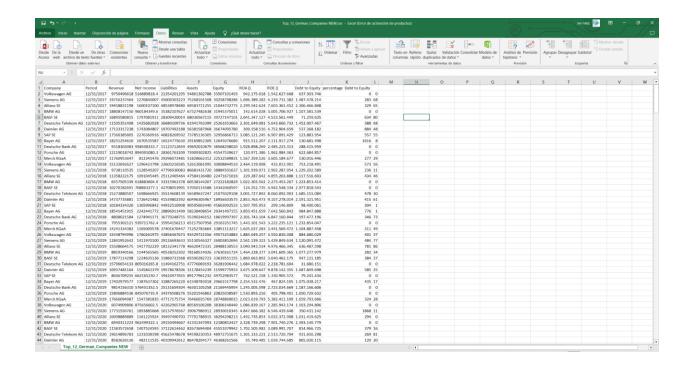
Dataset	2
Cluster	4
HUE	5
Manual de CRUD	6
HIVE	7
CRUD	9
Create	9
Read	10
Update	10
Delete	11
HBASE	12
CRUD	14
Create	14
Read	15
Update	15
Delete	16

## **Dataset**

Descargamos el dataset desde Kaggle, en nuestro caso son datos financieros de 12 empresas alemanas.



Al cargar el archivo en excel vemos que hay algunas columnas que como contienen comas, al hacer la división sobre ellas los datos se pasan de columnas. Para solucionar este problema vamos a eliminar la última columna ya que esta es la causante de estos problemas, además de que también contiene el carácter % que nos puede traer mas problemas aun al importar los datos después. Como vamos a crear nosotros la tabla a mano la primera fila, que es la de los nombres de las columnas, la vamos a borrar.



#### Los datos en formato correcto.

## Cluster

Creamos un clúster de hadoop de la manera que los hemos detallado en los anteriores ejercicios y subimos el archivo csv que hemos descargado de Kaggle al entorno de hadoop.

scp -i /home/iabd/Descargas/ClavesHadoop.pem /home/iabd/Descargas/Top\_12\_German\_Companies.csv hadoop@ec2-54-158-105-211.compute-1.amazonaws.com:/home/hadoop

```
(base) iabd@dm2-13:~$ scp -i /home/iabd/Descargas/ClavesHadoop.pem /home/iabd/Descargas/Top_12_German_Companies.csv hadoop@ec2-54-172-174-211.compute-1.amazonaws.com:/home/hadoop
Top_12_German_Companies.csv 100% 49KB 165.2KB/s 00:00
(base) iabd@dm2-13:~$
```

Tenemos que subirlo ahora del entorno al gestor de archivos de hadoop, así que creamos una carpeta y subimos el archivo.

hdfs dfs -mkdir Proyecto

hdfs dfs -put Top\_12\_German\_Companies.csv Proyecto

```
[hadoop@ip-172-31-85-225 ~]$ hdfs dfs -mkdir Proyecto
[hadoop@ip-172-31-85-225 ~]$ hdfs dfs -put Top_12_German_Companies.csv Proyecto
[hadoop@ip-172-31-85-225 ~]$ hdfs dfs -ls Proyecto
Found 1 items
-rw-r--r-- 1 hadoop hdfsadmingroup 47012 2024-12-03 18:16 Proyecto/Top_12
_German_Companies.csv
[hadoop@ip-172-31-85-225 ~]$
```

## HUE

Ahora venimos a aplicaciones del clúster de hadoop en AWS y pinchamos en Tonalidad.

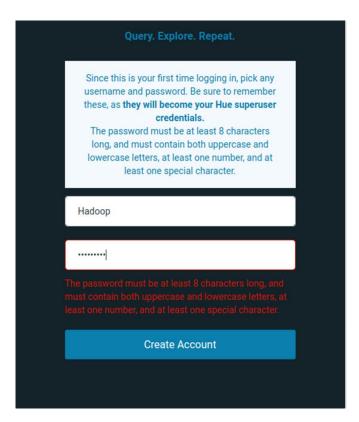


Nos pide crear un usuario.

HUE

User: Hadoop

Password: Hadoop1@



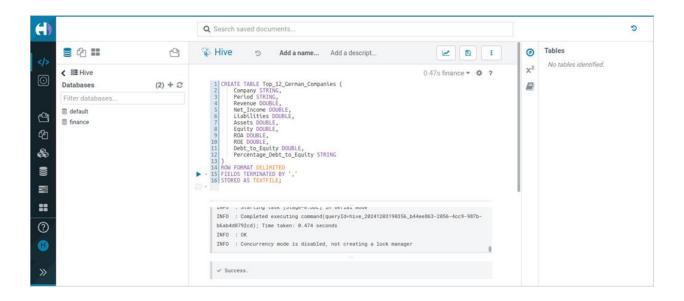
Accedemos a la interfaz de usuario de HUE donde desde esta podemos acceder a HIVE y HBase.

# Manual de CRUD

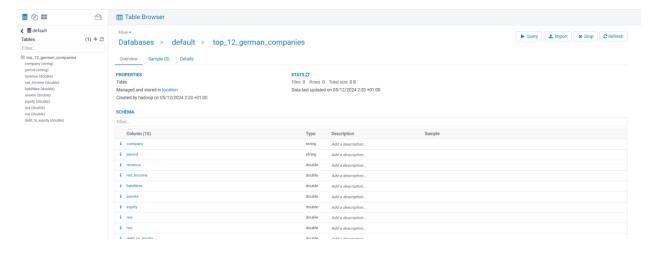
Operación	HBase	HIVE
Create	<pre>create 'table_name', 'column_family' put 'table_name', 'row_key', 'column_family:column_ name', 'value'</pre>	CREATE TABLE table_name (column_name data_type, column_name data_type)  CREATE TABLE new_table AS SELECT * FROM existing_table
Read	<pre>get 'table_name', 'row_key' scan 'table_name'</pre>	SELECT * FROM table_name
Update	<pre>put 'table_name',   'row_key',   'column_family:column_ name', 'new_value</pre>	<pre>UPDATE table_name SET column_name = new_value WHERE condition</pre>
Delete	<pre>delete 'table_name',   'row_key',   'column_family:column_   name'  deleteall   'table_name',   'row_key'</pre>	DELETE FROM table_name WHERE condition

## HIVE

Desde la interfaz de usuario de HUE, seleccionamos la BBDD de HIVE y creamos una tabla con desde la línea de comandos el siguiente código:



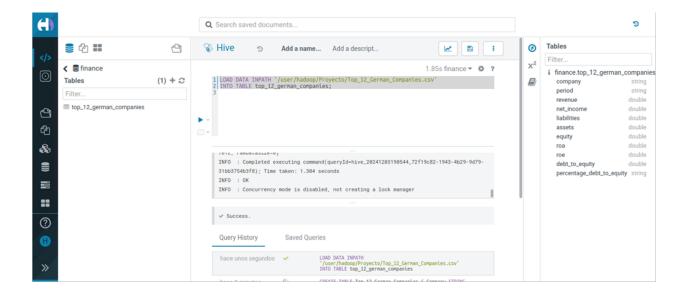
Una vez creada la tabla comprobamos que nos ha añadido todas las columnas y los tipos de datos de cada una correctamente.



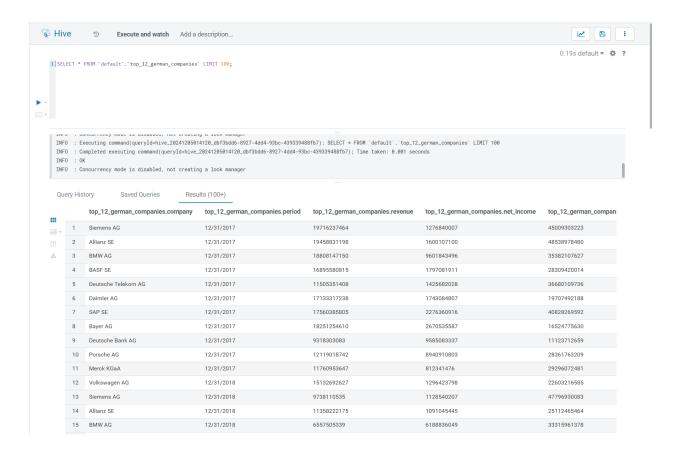
Ahora tenemos que cargar los datos que tenemos dentro del hdfs.

LOAD DATA INPATH'/user/hadoop/Proyecto/Top\_12\_German\_Companies.csv'

INTO TABLE top\_12\_german\_companies;



## Vemos que los datos insertados son correctos



## **CRUD**

#### Create

Al crear la BBDD lo hemos hecho, las capturas están arriba.

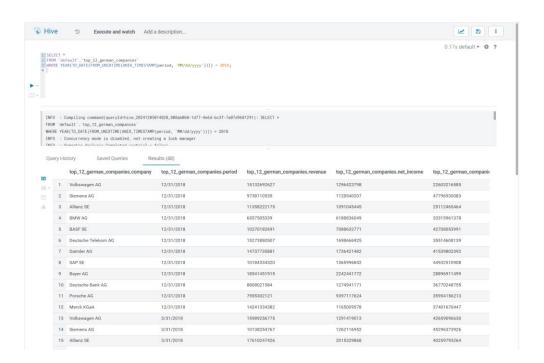
#### Read

Hacemos una consulta que nos devuelva todos los datos del 2018, tenemos que hacer la transformación de la fecha porque en nuestra BBDD está como String y no como date.

#### **SELECT \***

FROM `default`.`top\_12\_german\_companies`

WHERE YEAR(TO\_DATE(FROM\_UNIXTIME(UNIX\_TIMESTAMP(period, 'MM/dd/yyyy')))) = 2018;



## Update

```
UPDATE top_12_german_companies
SET company = 'Volkswagen'
WHERE company = 'Volkswagen AG';
```

```
Os default * * ?

1 UPDATE top_12_german_companies
2 EST company = 'Volkswagen'
3 MHERE company = 'Volkswagen A6';

Error while compiling statement: FAILED: SemanticException [Error 10294]: Attempt to do update or delete using transaction manager that does not support these operations.
```

Al intentar hacer un update nos produce un error, aunque la consulta sea correcta.

## Delete

DELETE FROM top\_12\_german\_companies

WHERE company = "Volkswagen AG"

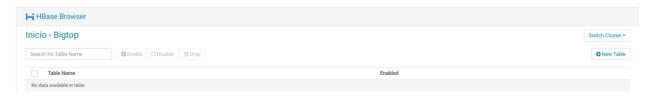
```
1 | DELETE FROM top_12_german_companies
2 | MHERE company = "Volkswagen AG"

Error while compiling statement: FAILED: SemanticException [Error 10294]: Attempt to do update or delete using transaction manager that does not support these operations.
```

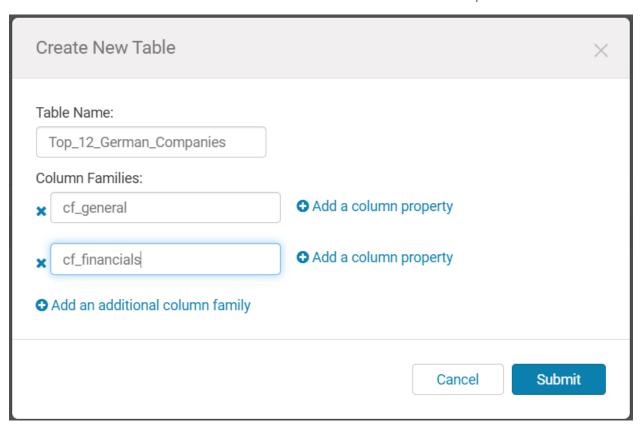
Al igual que con las modificaciones, tampoco nos deja eliminar filas.

## **HBASE**

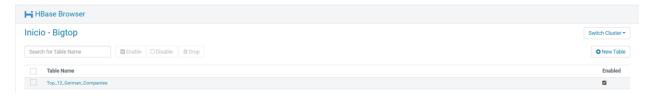
Dentro de HUE nos dirigimos a la pestaña de HBase y lo primero que tenemos que hacer es crear una nueva tabla.



Dentro de la creación le indicamos cuantas familias de columnas le queremos añadir.



Ya podemos ver que nos la ha creado.



Ahora nos vamos a la línea de comandos, al entorno donde tenemos instalado el hadoop y cargamos el csv que tenemos en hdfs a la tabla que hemos creado de HBase.

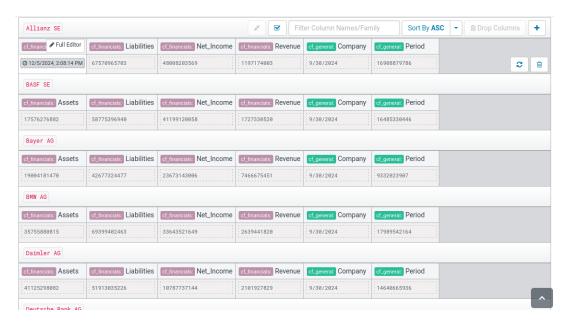
sudo hbase org.apache.hadoop.hbase.mapreduce.ImportTsv \ Dimporttsv.columns=HBASE\_ROW\_KEY,cf\_general:Company,cf\_general:Period,cf\_financials:
Revenue,cf\_financials:Net\_Income,cf\_financials:Liabilities,cf\_financials:Assets,cf\_financials:Equity \

-Dimporttsv.separator=',' \

Top\_12\_German\_Companies \

/user/hadoop/Top\_12\_German\_Companies.csv

cf\_financials van a contener los datos Revenue, Net\_Income, Liabilities, Assets y Equity, mientras que la columna cf\_general va contener información adicional como Company y Period.



Ahora nos vamos a conectar a la shell de HBase para hacer las consultas del CRUD.

[hadoop@ip-172-31-88-39 ~]\$ hbase shell

## **CRUD**

#### Create

put 'Top\_12\_German\_Companies', 'Siemens AG\_12/31/2017', 'cf\_general:Company', 'Siemens AG'

```
hbase:028:0> put 'Top_12_German_Companies', 'Siemens AG_12/312017', 'cf_general:
Company', 'Siemens AG'
Took 0.4440 seconds
hbase:029:0>
```

#### Read

get 'Top\_12\_German\_Companies', 'Siemens AG\_12/31/2017'

```
hbase:029:0> get 'Top_12_German_Companies', 'Siemens AG_12/312017'
COLUMN CELL
cf_general:Company timestamp=2024-12-05T19:20:48.404, value=Siemens AG
1 row(s)
Took 0.0389 seconds
```

## Update

En hbase el comando put crea en caso de que no exista pero también modifica en el caso en el que si lo haga.

put 'Top\_12\_German\_Companies', 'Siemens AG\_12/31/2017', 'cf\_financials:Net\_Income', '1300000000'

```
hbase:030:0> put 'Top_12_German_Companies', 'Siemens AG_12/312017', 'cf_financia
ls:Net_Income', '1300000'
Took 0.0095 seconds
```

## Comprobación

```
hbase:031:0> get 'Top_12_German_Companies', 'Siemens AG_12/312017'

COLUMN CELL

cf_financials:Net_In timestamp=2024-12-05T19:25:05.555, value=1300000

come

cf_general:Company timestamp=2024-12-05T19:20:48.404, value=Siemens AG
1 row(s)

Took 0.0070 seconds
```

#### Delete

deleteall 'Top\_12\_German\_Companies', 'Siemens AG\_12/31/2017'

Para eliminar toda la fila con la clave Siemens AG\_12/31/2017:

```
hbase:032:0> deleteall 'Top_12_German_Companies', 'Siemens AG_12/312017'
Took 0.0133 seconds
hbase:033:0> get 'Top_12_German_Companies', 'Siemens AG_12/312017'
COLUMN CELL
0 row(s)
Took 0.0049 seconds
hbase:034:0>
```